

PRZETWARZANIE DANYCH

SZUKANIE BŁĘDÓW, BRAKÓW; PCA; NORMALIZACJA


DATASET Z IRYSAMI



Dataset z irysami (iris dataset) to jeden z najbardziej popularnych zbiorów danych do prostych testów. Zawiera 150 rekordów z pomiarami płatków trzech gatunków irysa:

- Iris setosa
- Iris virginica
- Iris versicolor

Po 50 z każdego gatunku. Na naszych zajęciach będziemy korzystać z wersji dużej, po 500 każdego gatunku (1500 razem). Dla każdego irysa wykonano pomiar długości i szerokości płatka wywiniętego do góry (petal) i płatka wywiniętego w dół (sepal). Dodatkowo w piątej kolumnie datasetu są informacje o gatunku.



	sepal length	sepal width	petal length	petal width	target
0	5.1	3.5	1.4	0.2	Iris-setosa
1	4.9	3.0	1.4	0.2	Iris-setosa
2	4.7	3.2	1.3	0.2	Iris-setosa
3	4.6	3.1	1.5	0.2	Iris-setosa
4	5.0	3.6	1.4	0.2	Iris-setosa

Do przetwarzania pliku csv zawierającego dane warto użyć paczki pandas. Przetestuj:

```
import pandas as pd

df = pd.read_csv("iris_big.csv")

print(df)
```

W obiekcie df mamy bazę danych typu dataframe. Żeby bezpośrednio wejść do danych z tej bazy trzeba odwołać się do wartości (values).

```
print(df.values)
```

Spróbujmy wyświetlić różne fragmenty danych.

```
#wszystkie wiersze, kolumna nr 0
print(df.values[:, 0])

#wiersze od 5 do 10, wszystkie kolumny
print(df.values[5:11, :])

#dane w komórce [1,4]
print(df.values[1, 4])
```

📁 ZADANIE 1: BŁĘDY I BRAKUJĄCE DANE W IRYSACH

Ściągnij ze strony zajęć plik `iris_big_with_errors.csv`. Znajduje się w nim baza danych z irysami, jednak są w niej błędy. Celem zadania jest poprawienie tych błędów. Błędy można poprawić swoimi skryptami lub wykorzystanie do tego specjalistycznych paczek np. Pandas (<https://realpython.com/python-data-cleaning-numpy-pandas/>)

W naprawie pliku możesz kierować się poniższymi wskazówkami.

- Czy dane są w czterech kolumnach? Czy dataset ma dobrą strukturę? Jakie błędy zaburzają strukturę?
- Policz ile jest w bazie brakujących lub nieuzupełnionych danych. Wyświetl statystyki bazy danych z błędami.
- Sprawdź czy wszystkie dane numeryczne są z zakresu (0; 15). Dane spoza zakresu muszą być poprawione. Możesz tutaj użyć metody: za błędne dane podstaw średnią (lub medianę) z danej kolumny.
- Sprawdź czy wszystkie gatunki są napisami: „setosa”, „versicolor” lub „virginica”. Jeśli nie, wskaż jakie popełniono błędy i popraw je własną (sensowną) metodą.

📁 ZADANIE 2: PCA

Ściągnij czystą, bezbłędną bazę danych z irysami `iris_big.csv`

Następnie wykorzystując technikę PCA, chcemy skompresować bazę danych z czterech do trzech lub dwóch kolumn numerycznych, nie tracąc przy tym zbyt wiele informacji.

Wybierz paczkę i samouczek do zadania, np.:

- https://scikit-learn.org/stable/auto_examples/decomposition/plot_pca_iris.html
- <https://notebook.community/hershaw/data-science-101/course/class1/pca/iris/PCA%20-%20Iris%20dataset>
- <https://builtin.com/machine-learning/pca-in-python>

Możesz też skorzystać z programu pokazanego na wykładzie:

```
from sklearn import datasets
from sklearn.decomposition import PCA
import pandas as pd



iris = datasets.load_iris()
X = pd.DataFrame(iris.data, columns=iris.feature_names)
y = pd.Series(iris.target, name='FlowerType')
print(X.head())

pca_iris = PCA(n_components=3).fit(iris.data)
print(pca_iris)
print(pca_iris.explained_variance_ratio_)
print(pca_iris.components_)
print(pca_iris.transform(iris.data))
```

Dokonaj PCA na bazie danych. Przyjrzyj się nowym kolumnom i wariancjom. Ile kolumn można usunąć, tak aby zachować minimum 95% wariancji (strata informacji nie może być większa niż 5%)? Korzystając z poniższego wzoru, swoją odpowiedź uzasadnij.

$$\text{Strata informacji spowodowana usunięciem i ostatnich kolumn} = \frac{\sum_{k=n-i}^{n-1} \text{Var}(\text{kolumna}[k])}{\sum_{k=0}^{n-1} \text{Var}(\text{kolumna}[k])}$$

Bazę danych z usuniętymi kolumnami zobrazuj na wykresie punktowym, gdzie każdy punkt to irys. Jeśli w bazie zostawisz 2 kolumny, to wykres będzie na płaszczyźnie, a jeśli 3, to będzie trójwymiarowy. Przykłady:



ZADANIE 3: NORMALIZACJA

Najpierw spróbuj wykonać zadanie samodzielnie, a następnie wykorzystaj ChatGPT, lub Google Gemini lub inne narzędzie do rozwiązania tego zadania i zapisz użyte przez Ciebie prompty. Zadanie:

Stwórz wykresy z irysami jako punktami na wykresie, dla dwóch zmiennych: sepal length i sepal width. Klasy irysów oznaczone są w legendzie wykresu. Zrób wykres w trzech wersjach: dane oryginalne, znormalizowane min-max i zeskaleowane z-scorem. Wynik powinien przypominać ten poniżej.

Co możesz powiedzieć o min, max, mean, standard deviation dla tych danych?

